

Prediksi Pembatalan Hotel & Optimasi Kebijakan Deposit

Oleh: Muchlis Ar Wicaksana Program: Bootcamp Data Science 2026 – Devlaunch

Tujuan Proyek (Goals):

1. Mengidentifikasi pola lead time dan deposit type yang memicu pembatalan.
1. Membersihkan missing value pada kolom agen dan riwayat preferensi kamar.
1. Membangun model klasifikasi dengan F1-Score $\geq 82\%$.
1. Feature Engineering ekstraksi tanggal untuk uji hipotesis holiday season.
1. Merancang Dynamic Cancellation Policy.

Import Library

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, confusion_matrix, f1_score
```

Data Understanding

Tahap ini bertujuan untuk memuat data dan memahami struktur awal dataset, tipe data, serta mengecek distribusi target kelas `is_cancelled`.

```
# load dataset
df = pd.read_csv('../data/raw/hotels.csv')

# Menampilkan 5 baris pertama
display(df.head())

# Melihat dimensi data
print('\n--- Dimensi Data ---')
print(f'Jumlah Baris: {df.shape[0]}')
print(f'Jumlah Kolom: {df.shape[1]}')

# Melihat informasi struktur data
print('\n--- Info Dataset ---')
df.info()

# Melihat Missing Values
print('\n--- Missing Values ---')
missing_values = df.isnull().sum()
print(missing_values[missing_values > 0])

# Melihat prporasi target (imbalance check)
```

```

print('\n--- Proporsi Target (is_canceled) ---')
print(df['is_canceled'].value_counts(normalize=True) * 100)

--- Dimensi Data ---
Jumlah Baris: 119390
Jumlah Kolom: 32

--- Info Dataset ---
<class 'pandas.DataFrame'>
RangeIndex: 119390 entries, 0 to 119389
Data columns (total 32 columns):
#   Column                                     Non-Null Count  Dtype
---  -
0   hotel                                     119390 non-null  str
1   is_canceled                             119390 non-null  int64
2   lead_time                               119390 non-null  int64
3   arrival_date_year                       119390 non-null  int64
4   arrival_date_month                     119390 non-null  str
5   arrival_date_week_number               119390 non-null  int64
6   arrival_date_day_of_month              119390 non-null  int64
7   stays_in_weekend_nights                119390 non-null  int64
8   stays_in_week_nights                   119390 non-null  int64
9   adults                                  119390 non-null  int64
10  children                                119386 non-null  float64
11  babies                                  119390 non-null  int64
12  meal                                     119390 non-null  str
13  country                                 118902 non-null  str
14  market_segment                         119390 non-null  str
15  distribution_channel                   119390 non-null  str
16  is_repeated_guest                      119390 non-null  int64
17  previous_cancellations                  119390 non-null  int64
18  previous_bookings_not_canceled          119390 non-null  int64
19  reserved_room_type                     119390 non-null  str
20  assigned_room_type                     119390 non-null  str
21  booking_changes                         119390 non-null  int64
22  deposit_type                           119390 non-null  str
23  agent                                  103050 non-null  float64
24  company                                 6797 non-null   float64
25  days_in_waiting_list                   119390 non-null  int64
26  customer_type                           119390 non-null  str
27  adr                                     119390 non-null  float64
28  required_car_parking_spaces             119390 non-null  int64
29  total_of_special_requests               119390 non-null  int64
30  reservation_status                     119390 non-null  str
31  reservation_status_date                 119390 non-null  str
dtypes: float64(4), int64(16), str(12)
memory usage: 29.1 MB

--- Missing Values ---
children      4
country      488
agent      16340
company     112593
dtype: int64

--- Proporsi Target (is_canceled) ---
is_canceled
0      62.958372
1      37.041628
Name: proportion, dtype: float64

```

Data Cleaning & Preparation

Kita akan menangani missing values khususnya pada kolom agent dan mengevaluasi riwayat preferensi kamar tamu.

```
df_clean = df.copy()

# Membersihkan data kosong pada `agent`
# Mengubah string NULL menjadi NaN, dan mengisi NaN dengan 0 artinya direct/tanpa agent
df_clean['agent'] = df_clean['agent'].replace('NULL', np.nan).fillna(0)
# Ubah tipe data menjadi integer
df_clean['agent'] = pd.to_numeric(df_clean['agent'], errors='coerce').fillna(0).astype(int)

# Mengisi Missing value pada `country` dan `children`
# Mengisi kolom country dengan modus
df_clean['country'] = df_clean['country'].fillna(df['country'].mode()[0])
# Mengisi missing value pada `children` dengan 0 karena diasumsikan tidak membawa anak
df_clean['children'] = df_clean['children'].fillna(0)

# Riwayat referensi kamar
# Jika reserved_room_type berbeda dengan assigned_room_type, tamu tidak mendapat kamar yang
df_clean['room_changed'] = np.where(df_clean['reserved_room_type'] != df_clean['assigned_room_type'], 1, 0)

# Drop kolom berlebih yang dapat menyebabkan data leakage
# reservation_status sangat membocorkan informasi apakah tamu batal atau tidak
drop_cols = ['reservation_status', 'reservation_status_date', 'company']
df_clean.drop(columns=[col for col in drop_cols if col in df_clean], inplace=True)

print('Jumlah data setelah dibersihkan:')
print(f'Jumlah Baris: {df_clean.shape[0]}')
print(f'Jumlah Kolom: {df_clean.shape[1]}')
print(f'\nMissing values tersisa:\n', df_clean.isnull().sum().max())

Jumlah data setelah dibersihkan:
Jumlah Baris: 119390
Jumlah Kolom: 30

Missing values tersisa:
0
```

Insight Data Cleaning:

```
df_clean.to_csv('../data/processed/data_clean.csv')
```

Feature Engineering

Melakukan ekstraksi tanggal untuk menguji hipotesis pengaruh musim liburan (holiday season)

```
# Asumsi holiday season: Juli, Agustus (summer) dan Desember (Winter/End Year)
holiday_months = ['July', 'August', 'December']
df_clean['is_holiday_season'] = np.where(df_clean['arrival_date_month'].isin(holiday_months), 1, 0)

# Verifikasi fitur baru
print('Proporisi pemesanan pada holiday season vs non-holiday:')
print(df_clean['is_holiday_season'].value_counts(normalize=True) * 100)

Proporisi pemesanan pada holiday season vs non-holiday:
```


```
is_holiday_season
0    72.09314
1    27.90686
Name: proportion, dtype: float64
```

Insight Feature Engineering (Holiday Season):


Exploratory Data Analysis (EDA)

Menjawab pola Lead Time & Ddeposit Type dan menguji hipotesis.

```
# Pengaruh Lead Time Terhadap Pembatalan
plt.figure(figsize=(10, 6))
ax = sns.boxplot(x='is_canceled', y='lead_time', hue='is_canceled', data=df_clean, palette=
plt.title('Distribusi Lead Time Berdasarkan Status Pembelian')
plt.xticks(ticks=[0, 1], labels=['Tidak Batal', 'Batal'])
ax.legend_ = None
plt.show()
```



```
# Pengaruh Deposit Type
plt.figure(figsize=(10, 6))
ax = sns.countplot(x='deposit_type', hue='is_canceled', data=df_clean, palette='Set2')
plt.title('Pembatalan Berdasarkan Tipe Deposit')
plt.legend(title='Status', labels=['Tidak Batal', 'Batal'])
plt.xlabel('Tipe Deposit')
plt.ylabel('Jumlah Pesanan')
for container in ax.containers:
    ax.bar_label(container, fmt='%d', padding=3)
plt.show()
```



Pengaruh Holiday Season

```
plt.figure(figsize=(10, 6))
```

```
ax = sns.countplot(x='is_holiday_season', hue='is_canceled', data=df_clean, palette='Set2')
```

```
plt.xticks(ticks=[0, 1], labels=['Reguler\n(9 Bulan)', 'Holiday\n(3 Bulan)'])
```

```
plt.title('Volume Transaksi: Reguler vs Holiday')
```

```
plt.legend(title='Status', labels=['Tidak Batal', 'Batal'])
```


```
plt.xlabel('Musim')
```

```
plt.ylabel('Jumlah Pemesanan')
```

```
for container in ax.containers:
```

```
    ax.bar_label(container, fmt='%d', padding=3)
```

```
plt.show()
```



Insight Komprehensif Exploratory Data Analysis (EDA):

Modeling & Evaluation

Membangun arsitektur model klasifikasi dengan target kestabilan F1-Score $\geq 82\%$. Kita menggunakan Random Forest yang bisa menangani data campuran numerik dan kategorikal.

Data Preparation

```
# Menyiapkan fitur (X) dan target (y)
X = df_clean.drop(columns=['is_canceled', 'arrival_date_year'])
y = df_clean['is_canceled']

# Memisahkan numerik dan kategorikal untuk pipeline
num_features = X.select_dtypes(include=['int64', 'float64', 'int32']).columns
cat_features = X.select_dtypes(include=['object', 'str']).columns

# Pipeline Preprocessing
preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), num_features),
        ('cat', OneHotEncoder(handle_unknown='ignore'), cat_features)
    ]
)
```

Data Splitting & Training Model

```
# Data Splitting
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, s

# Pipeline model random forest
rf_pipeline = Pipeline(steps=[
    ('preprocessor', preprocessor),
    ('classifier', RandomForestClassifier(n_estimators=100, random_state=42, n_jobs=1))
])

# Training Model
print('Training Model sedang berjalan')
rf_pipeline.fit(X_train, y_train)
print('Training Selesai...')

    Training Model sedang berjalan
    Training Selesai...
```

Evaluasi

```
# Prediksi
y_pred = rf_pipeline.predict(X_test)

# Evaluasi
print('--- Classification Report ---')
print(classification_report(y_test, y_pred))

# Memeriksa target F1-Score
f1 = f1_score(y_test, y_pred)
print(f'\nF1-Score Model: {f1:.2%}')


# Confusion Matrix
plt.figure(figsize=(6,4))
sns.heatmap(confusion_matrix(y_test, y_pred), annot=True, fmt='d', cmap='Blues')
plt.title('Confusion Matrix - Random Forest')
plt.xlabel('Prediksi')
plt.ylabel('Aktual')
plt.show()
```

```
--- Classification Report ---
              precision    recall  f1-score   support

         0       0.89      0.94      0.92     15033
         1       0.89      0.80      0.85      8845

 accuracy      0.89      0.87      0.88     23878
 macro avg     0.89      0.87      0.88     23878
weighted avg     0.89      0.89      0.89     23878
```

F1-Score Model: 84.57%



Insight Modeling:

Kesimpulan & Rekomendasi Bisnis

A. Kesimpulan Teknis & Analisis

- **Performa Model Standar Industri:** Arsitektur klasifikasi menggunakan *Random Forest Pipeline* berhasil melampaui target awal dengan mencetak **F1-Score di atas 82%**. Model ini terbukti tangguh dan stabil dalam membedakan tamu yang akan benar-benar menginap dengan yang memiliki intensi membatalkan pesanan.
- **Katalis Utama Pembatalan:** *Exploratory Data Analysis* (EDA) mengungkap tiga faktor pemicu utama risiko operasional:
 1. **Lead Time Panjang:** Semakin jauh jarak hari antara pemesanan dan kedatangan (terutama di atas 100 hari), semakin eksponensial risiko pembatalan sepihak.
 1. **Anomali Non-Refundable:** Ditemukan lonjakan ekstrem (lebih dari 14.000 pembatalan) justru pada tipe deposit *Non-Refundable*. Ini mengindikasikan adanya penyalahgunaan sistem *block-booking* secara massal oleh mitra/agen perjalanan.
 1. **Kerentanan Holiday Season:** Walaupun hanya berlangsung 3 bulan, musim liburan menyumbang hampir 28% total volume pemesanan. Kepadatan ini membuat hotel sangat rentan terhadap *opportunity cost* dalam rentang waktu yang sempit.

B. Rekomendasi Bisnis: Perancangan *Dynamic Cancellation Policy*

Untuk mentransformasi *insight* data menjadi nilai bisnis yang nyata, kami merekomendasikan penerapan **Kebijakan Pembatalan Dinamis (*Dynamic Cancellation Policy*)** dengan 3 tingkatan mitigasi risiko: